Predição de atrasos em pedidos de venda usando grafos heterogêneos

Angelo João Sagnori[1*]; Edilson José Rodrigues[2]

[1*] Pós-graduando em Data Science e Analytics - USP/ESALQ. E-mail: angelo.sagnori@usp.br
[2] Prof. Dr. em Data Science e Analytics - USP/ESALQ. E-mail: edilson.rodrigues@usp.br

Predição de atrasos em pedidos de venda usando grafos heterogêneos

Resumo

Este trabalho propôs a aplicação de Grafos Heterogêneos para a predição de atrasos em pedidos de venda usando o framework GraphSAGE implementado com a biblioteca PyTorch Geometric. Diferentemente das abordagens tabulares tradicionais que deixam de explorar a topologia dos dados, esta pesquisa explorou as dependências do conjunto de dados Bike Store, modelado em um grafo com N = 8.132 de nós e E = 15.880 de arestas. A metodologia envolve a comparação entre um baseline em XGBoost e a arquitetura GNN, tratando o desbalanceamento de classe identificado na análise exploratória (31,69% de atrasos). A explicabilidade do modelo é investigada por meio do GNNExplainer, visando fornecer transparência às decisões preditivas no contexto de Supply Chain. Os resultados obtidos indicam que a modelagem relacional baseada em grafos heterogêneos constitui uma abordagem promissora para capturar gargalos logísticos entre produtos, lojas e categorias.
Palavras-chave: Relational Deep Learning (RDL); Graph Neural Networks (GNN); GraphSAGE; PyTorch Geometric; Graph Representation Learning.

Predicting sales order delays using heterogeneous graphs

Abstract

This study proposes the application of Heterogeneous Graphs for predicting sales order delays using the GraphSAGE framework implemented with the PyTorch Geometric library. Unlike traditional tabular approaches, which do not exploit the underlying topology of relational data, this research models the Bike Store dataset as a heterogeneous graph comprising 8,132 nodes and 15,880 edges. The proposed methodology compares a baseline XGBoost model with a Graph Neural Networks (GNN) architecture while addressing the class imbalance identified during the exploratory data analysis, in which 31.69% of the sales orders were delayed. Model interpretability is investigated using GNNExplainer, aiming to provide transparency and explainability for predictive decisions in a Supply Chain context. The results obtained indicate that relational modeling based on heterogeneous graphs constitutes a promising approach for capturing logistical bottlenecks among products, stores, and categories.
Keywords: Relational Deep Learning (RDL); Graph Neural Networks (GNN); GraphSAGE; PyTorch Geometric; Graph Representation Learning.

Introdução

A operação de organizações modernas hoje é sustentada por ecossistemas de dados relacionais, gerenciados por sistemas de ERP e CRM. Apesar dessa riqueza estrutural desses sistemas, a prática convencional em Ciência de Dados ainda se baseia na maioria das vezes no processo de “achatamento” (flattening) dessas tabelas por meio de junções, resultando em matrizes tabulares planas. Esse processo dificulta a preservação de dependências estruturais relevantes entre as entidades do banco de dados e limita uma representação mais fiel do fenômeno analisado (Cvitkovic, 2020; Robinson et al., 2024). Nesse contexto, temos o campo do Relational Deep Learning '[RDL]', que propõe o aprendizado de representações diretamente sobre grafos a partir de bases relacionais, preservando a estrutura original dos

dados e ampliando a capacidade analítica sobre interações entre as entidades (Robinson et al., 2024).

As Redes Neurais em Grafos (GNNs) têm sua relevância em diferentes domínios exatamente por sua aptidão em aprender padrões a partir de dependências estruturais complexas, o que as torna particularmente úteis para problemas em que relações entre objetos influenciam diretamente o resultado observado (Khemani et al., 2024). A aplicação dessa abordagem à predição de atrasos em pedidos de venda mostra-se pertinente, já que que esse tipo de evento dificilmente acontece em fatores isolados, sendo associado a interações entre produtos, categorias, clientes, lojas e fluxos operacionais. Em cenários desse tipo, a modelagem relacional pode oferecer vantagens em relação a abordagens tabulares tradicionais, por representar conexões que seriam parcialmente perdidas no processo de transformação dos dados. Além disso, a arquitetura GraphSAGE permite aprendizado em grafos de grande escala, agregando informações das vizinhanças dos nós e favorecendo a generalização para novos dados (Hamilton et al., 2017).

Do ponto de vista aplicado a proposta também se beneficia de bibliotecas especializadas disponíveis, como o PyTorch Geometric, que viabilizam a implementação eficiente de modelos de aprendizado em grafos em ambientes experimentais e corporativos (Fey e Lenssen, 2019). Esse estudo se justifica por investigar uma abordagem metodológica mais aderente à natureza relacional do problema de atraso em pedidos de venda mais potencialmente do que os modelos tabulares tradicionalmente empregados, uma vez que a predição de atrasos pode apoiar respostas proativas da operação logística e contribuir para a melhoria do nível de serviço ao cliente, bem como para a mitigação de impactos financeiros associados aos atrasos (Sarbas et al., 2023). Com essa complexidade da cadeia de suprimentos atualmente, esse trabalho busca responder como a incorporação da topologia de dados relacionais por meio de redes neurais em grafos heterogêneos pode ser superior ao desempenho de modelos tabulares clássicos na predição de atrasos.

Direcionando a investigação, formulam-se duas hipóteses principais: H0 da equivalência estatística no desempenho preditivo mensurado pelo F1-Score entre o modelo GraphSAGE e o baseline XGBoost e H1 no qual a arquitetura de rede neural em grafo heterogêneo supera o desempenho do XGBoost capturando as dependências contextuais entre múltiplos tipos de nós que tendem a ser negligenciadas em representações tabulares planas. O objetivo do trabalho é desenvolver e avaliar um modelo de Redes Neurais em Grafos Heterogêneos para a classificação binária dos atrasos em pedidos de venda utilizando o conjunto de dados chamado Bike Store. Visando comparar o desempenho da arquitetura GraphSAGE frente ao algoritmo XGBoost, e investigar a explicabilidade das predições por meio da técnica GNNExplainer.

Material e Métodos

Na realização deste estudo utilizou-se o conjunto de dados público relacional Bike Store, que reflete a operação de uma rede de varejo de bicicletas. A base original composta por tabelas relacionais conectadas entre si, foi mapeada para uma estrutura de grafo heterogêneo utilizando a biblioteca PyTorch Geometric. Sendo que o grafo construído compreende 8.132 nós (N), segmentados entre as entidades: clientes (1.445), pedidos (1.615), itens de pedido (4.722), produtos (321), funcionários (10), lojas (3), marcas (9) e categorias (7). As relações entre as entidades totalizam 15.880 arestas (E), representando relações fundamentais como o vínculo entre pedidos e seus respectivos itens, a associação de produtos a marcas e categorias, e a alocação de pedidos a lojas e vendedores específicos. A variável-alvo foi definida de forma binária a partir da comparação entre a data efetiva de entrega do pedido e a data prometida de entrega. Pedidos entregues após o prazo estabelecido foram rotulados como atraso, enquanto os demais compuseram a classificação sem atraso.

A estruturação dos dados usou uma estratégia de engenharia de atributos (feature engineering) específica a cada tipo de nó. Atributos numéricos, como preços e quantidades, foram normalizados, enquanto variáveis categóricas (cidades, estados e modelos) foram tratadas via one-hot encoding. As representações semânticas de descrições textuais de produtos para o catálogo referente ao período de 2016 a 2018 enriqueceram o vetor de características dos nós com informações semânticas e temporais de modelos e descrições técnicas. Para as arestas foram incorporados atributos que qualificam a relação, como níveis de estoque e volumes transacionados.

O diagrama abaixo (Figura 1) ilustra a topologia de rede relacional, onde as arestas direcionadas indicam o fluxo de agregação de mensagens. Os arcos recursivos sobre cada nó representam a implementação de identidades ou self-loops, garantindo a preservação das características próprias de cada entidade nas camadas da rede neural.

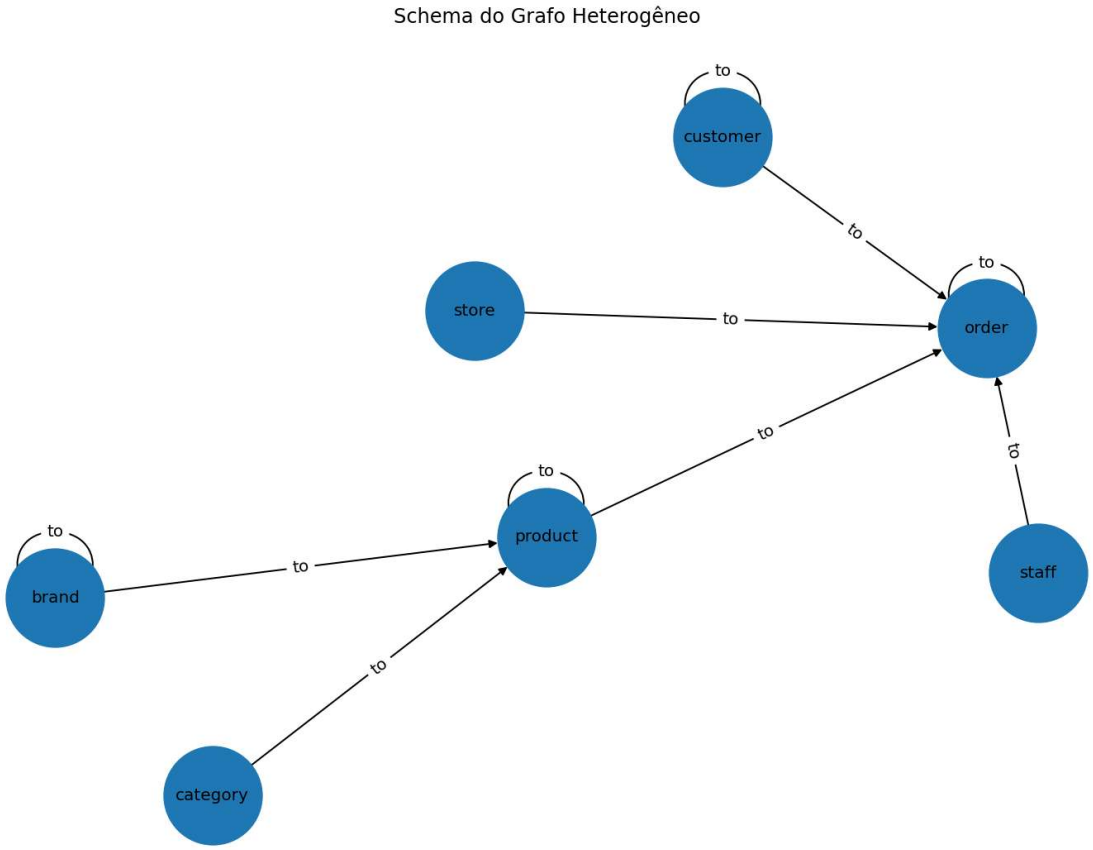


Figura 1. Schema do Grafo Heterogêneo
Fonte: Dados originais da pesquisa

Um dos pontos críticos na metodologia de dados temporais refere-se à estratégia de divisão dos dados (split) e para mitigar o vazamento de dados (data leakage) que ocorre quando informações do futuro influenciam o treinamento do modelo, optou-se por uma divisão estritamente cronológica ordenada pela data do pedido (order_date), em detrimento de uma amostragem aleatória. Para a etapa de validação, empregou-se a técnica de Time Series Split configurada com K= 4 folds temporais. Essa estratégia foi executada por meio de uma janela acumulativa para o conjunto de treinamento, na qual cada fold subsequente incorpora todo o histórico disponível até aquele momento. Em contrapartida, a validação é realizada sobre uma janela móvel de tamanho fixo, contendo aproximadamente 323 instâncias por fold, permitindo avaliar a capacidade preditiva do modelo no bloco temporal imediatamente posterior. Para evidenciar a estabilidade preditiva do modelo frente às oscilações sazonais e minimizar distorções decorrentes de um único período de avaliação, as métricas de desempenho foram agregadas por meio da média e do desvio padrão obtidos nas quatro folds avaliadas. Na etapa de modelagem preditiva, implementou-se a arquitetura de Redes Neurais em Grafos GraphSAGE (Graph Sample and Aggregate), essa escolha se justifica pela sua capacidade de um aprendizado indutivo, permitindo gerar representações (embeddings) para nós que não

estavam presentes durante o treinamento. O modelo de baseline XGBoost Classifier foi submetido ao mesmo protocolo rigoroso de divisão temporal e reponderação dinâmica do desbalanceamento por fold (scale_pos_weight), garantindo a comparabilidade direta de desempenho por meio de métricas como F1-Score, Precisão e Revocação focadas na classe de atrasos.

Devido ao desbalanceamento de classes encontrado nos testes preliminares, o desempenho foi avaliado com foco na classe de atrasos (Classe 1) por meio de Precisão, Revocação (Recall) e F1-Score (entre os K= 4 folds temporais), além da Acurácia Global. Para testar se a GraphSAGE supera o XGBoost (hipótese H1) ou se mantém equivalente (hipótese H0), aplicou-se o teste t de student pareado sobre o F1-Score dos folds aplicados.

Para abrir a "caixa-preta" dos algoritmos, utilizou-se o SHAP (SHapley Additive exPlanations) no XGBoost, quantificando o impacto de cada variável tabular, e o GNNExplainer na GraphSAGE, identificando os atributos de nós mais influentes no grafo heterogêneo. Essa abordagem permitiu comparar os fatores determinantes do atraso sob as perspectivas tabular e relacional.

A revisão linguística e a adequação às regras gerais de formatação deste documento contaram com o suporte da inteligência artificial institucional da USP. Adicionalmente, utilizou-se a ferramenta GitHub Copilot para a revisão técnica dos códigos e scripts desenvolvidos, sendo a validação final, supervisão crítica e consolidação de todo o conteúdo executadas integralmente pelo autor.

Resultados e Discussão

A tabela comparativa abaixo (Figura 2) apresenta a síntese do desempenho médio e desvio padrão obtidos pelo baseline XGBoost e pela arquitetura GraphSAGE ao longo dos K= 4 folds da validação cruzada temporal (Time Series Split).

Metric (CLASS: Delayed)	DUMMY Classifier	XGBOOST Baseline	GRAPHSAGE GNN
Global Accuracy	57.28% ± 2.33%	46.67% ± 7.52%	50.62% ± 5.98%
Class Precision	-	0.2873 ± 0.0902	0.2832 ± 0.0843
Class Recall	-	0.6064 ± 0.2152	0.5115 ± 0.2156
F1-Score	0.2647 ± 0.0736	0.3829 ± 0.1099	0.3541 ± 0.1107
PR-AUC (Precision-Recall)	0.2777 ± 0.0729	0.2978 ± 0.0921	0.3114 ± 0.0865

Figura 2. Comparativo de Desempenho

Fonte: Dados originais da pesquisa

Inicialmente, a aplicação do Grafo Heterogêneo sobre o dataset Bike Store sem reponderação de classes resultou em uma acurácia global de 76,71% em uma divisão simples. Contudo, a análise da matriz de confusão revelou um viés severo: enquanto a classe majoritária (No Prazo) obteve alto índice de acertos, a revocação (recall) para a classe minoritária (Atrasado) foi de apenas 3,85%. Esse comportamento confirmou que o sinal dos eventos de atraso estava diluído na transmissão de mensagens do grafo devido ao desbalanceamento de classes (31,69% na base total e 28,17% na média dos folds de teste). Esse diagnóstico motivou a adoção da reponderação dinâmica de classes e da validação cruzada temporal K = 4, cujos resultados consolidados são apresentados a seguir.

O gráfico da PR-AUC abaixo (Figura 3) apresentou as curvas acumuladas dos folds da validação temporal. A linha horizontal pontilhada estabelece a linha de base aleatória do modelo Dummy (PR-AUC = 0,2777), correspondente à prevalência média de atrasos na base transacional (28,17%). O modelo GraphSAGE obteve o maior valor global de PR-AUC (0,3114), seguido pelo XGBoost (0,2978).

A análise da curva revelou um ganho prático relevante da abordagem em grafos: para limiares de decisão de alta confiança (onde o Recall é inferior a 0,30), o GraphSAGE alcançou picos superiores de Precisão (próximos a 1,0), demonstrando melhor capacidade de ordenamento das instâncias de maior risco do que a abordagem tabular isolada. No entanto, à medida que o limiar de decisão é relaxado para capturar mais de 30% dos atrasos (Recall > 0,30), ambas as arquiteturas convergem em direção à linha de base aleatória. Esse comportamento justifica a ausência de significância estatística no teste t pareado sobre o F1-Score global (p= 0,61018), mas evidencia o valor do GraphSAGE para estratégias operacionais focadas na mitigação do top 10% a 20% de pedidos com maior risco de atraso.

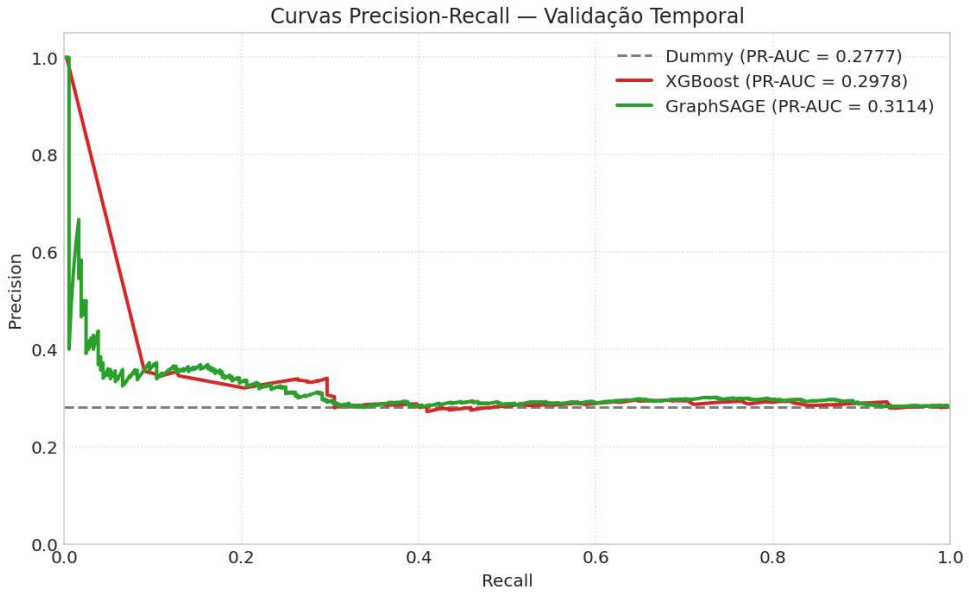


Figura 3. Curvas precision recall – validação temporal

Fonte: Dados originais da pesquisa

A análise dos resultados revela que ambas as abordagens alcançaram estabilidade e equilíbrio operacional semelhantes. A reponderação dinâmica das classes nos conjuntos de treinamento por fold permitiu elevar o recall da classe de atrasos (que em testes sem tratamento era inferior a 4%), atingindo 60,64% no XGBoost e 51,15% na GraphSAGE. Para testar formalmente a hipótese do estudo, aplicou-se o teste t de student pareado sobre os F1-Scores obtidos nos 4 folds temporais. O teste entre o XGBoost e o baseline dummy indicou uma tendência de ganho preditivo (t= 2,7311; p= 0,07187). Já a comparação direta entre a GraphSAGE e o XGBoost resultou em t= -0,5673 e p= 0,61018. Como p > 0,05, não se rejeita a hipótese nula (H_0), confirmando que não há diferença estatisticamente significante no F1-Score global entre a abordagem relacional em grafos e o baseline tabular sob o protocolo temporal avaliado.

Embora os modelos apresentem paridade em métricas quantitativas tabulares, a abordagem relacional oferece um ganho estrutural evidenciado pela análise de explicabilidade, pois incorpora as relações entre entidades do domínio o que permite interpretar as dependências que não são representadas em modelos tabulares.

A análise de explicabilidade SHAP do XGBoost, conforme ilustrado na Figura 4 abaixo revelou que as variáveis temporais e identificadores (order_month, staff_id, customer_id e required_month) exercem maior impacto nas decisões do modelo, avaliando cada pedido como um registro isolado.

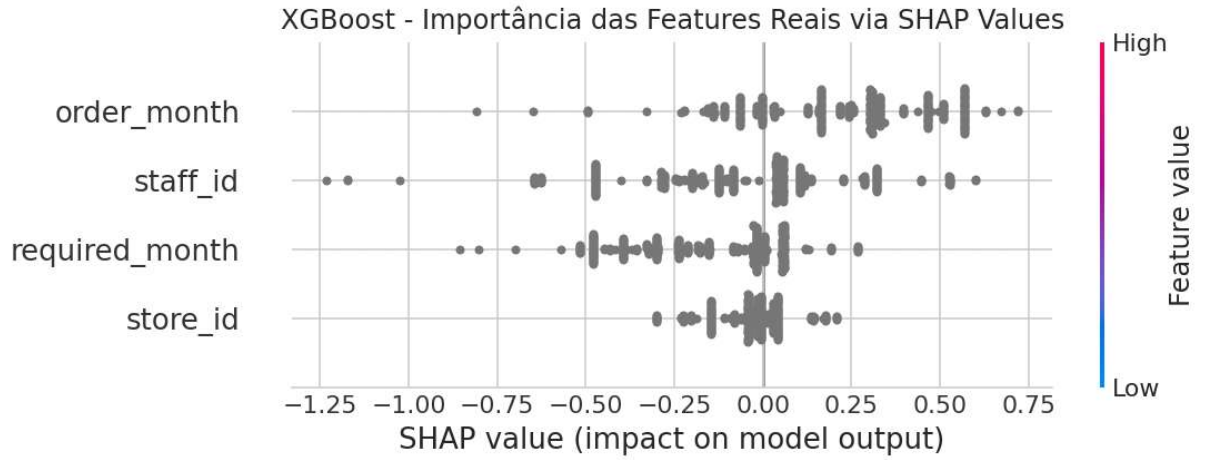


Figura 4. Features via SHAP para o XGBoost

Fonte: Dados originais da pesquisa

O algoritmo GNNExplainer estendeu a interpretação ao nível de rede, gerando máscaras de importância sobre os atributos de todas as entidades do grafo heterogêneo (customer, product, brand, category, store, staff e order). Para o pedido analisado, o explicador parece ter capturado o impacto combinado do perfil do cliente e da categoria do produto na propagação do risco de atraso, fornecendo uma visão contextual da cadeia logística que não pode ser extraída por modelos tabulares convencionais.

Conclusão

Este trabalho apresentou uma avaliação comparativa entre a arquitetura de Redes Neurais em Grafos GraphSAGE e o modelo baseline XGBoost para a predição de atrasos em pedidos de venda, utilizando o dataset Bike Store. Os resultados obtidos via validação cruzada temporal (Time Series Split com K= 4 folds) demonstraram que a GraphSAGE atingiu paridade operacional com o XGBoost, obtendo um F1-Score médio de 0,3541 contra 0,3829 do baseline (0,2647 do Dummy). O teste estatístico t pareado (t= -0,5673; p= 0,61018) confirmou a equivalência preditiva entre as abordagens (H_0), evidenciando que a adição da estrutura de rede não degradou o desempenho em um cenário de dados temporais restritos. A principal contribuição da modelagem em grafos heterogêneos reside na transparência e na ordenação de risco: além de atingir a maior PR-AUC global (0,3114), a combinação do grafo heterogêneo com o GNNExplainer permitiu mapear o impacto conjunto de entidades interconectadas (clientes, vendedores, lojas e categorias de produtos) na determinação do risco de atraso.

Concluo que os resultados sugerem que a modelagem relacional baseada em grafos contribui para a identificação de padrões estruturais associados a eventos de atraso nos pedidos de venda, que capturam as dependências entre clientes, produtos, marcas e pedidos que não são explicitamente representadas em abordagens tabulares.

Como trabalhos futuros, pretende-se investigar arquiteturas heterogêneas mais avançadas como a Heterogeneous Graph Transformer '[HGT]' e validação do protocolo experimental em bases de dados corporativas de grande escala na área de Supply Chain, contendo maior densidade relacional e maior histórico de transações.

Agradecimento

Agradeço a orientação no trabalho de conclusão e à USP/ESALQ pela oportunidade de desenvolvimento intelectual ao longo deste MBA. Agradeço também à minha família, pelo apoio, incentivo e compreensão, fundamentais para a realização deste trabalho.

Referências

Cvitkovic, M. 2020. Supervised learning on relational databases with graph neural networks. Amazon web services, **ArXiv preprint**. DOI 10.48550/arXiv.2002.02046. Disponível em: <https://doi.org/10.48550/arXiv.2002.02046>. Acesso em 10 mar. 2025.

Fey, M.; Lenssen, J. E. 2019. Fast graph representation learning with PyTorch geometric. **ArXiv preprint**. DOI 10.48550/arXiv.1903.02428. Disponível em: <https://doi.org/10.48550/arXiv.1903.02428>. Acesso em 16 mar. 2025.

Robinson, J.; Huang, K.; Rajan, R.; Leskovec, J.; Hu, W.; Fey, M.; Lenssen, J. E.; Ying, R.; You, J. 2024. Relational deep learning: graph representation learning on relational databases. **Relbench benchmark**, Stanford University, ArXiv preprint. DOI 10.48550/arXiv.2312.04615. Disponível em: <https://doi.org/10.48550/arXiv.2312.04615>. Acesso em 10 mar. 2025.

Khemani, B.; Patil, S.; Kotecha, K.; Tanwr, S. 2024. A review of graph neural networks: concepts, architectures, techniques, challenges, datasets, applications, and future directions. **Journal of big data**, v. 11, n. 18. DOI 10.1186/s40537-023-00876-4. Disponível em: <https://doi.org/10.1186/s40537-023-00876-4>. Acesso em 10 mar. 2025.

Hamilton, W. L.; Ying, R.; Leskovec, J. 2017. Inductive representation learning on large graphs. **NeurIPS**. DOI 10.48550/arXiv.1706.02216. Disponível em: <https://doi.org/10.48550/arXiv.1706.02216>. Acesso em 16 mar. 2025.

Sarbas, P.; Sanoob, K. S.; Sravan, K.; Hafiz, V. S. 2023. Development of predictive models for order delivery risk in a supply chain: A machine learning approach. In: emerging trends in mechanical and industrial engineering. **Singapore: springer**. DOI: 10.1007/978-981-19-6945-4_43. Disponível em: <https://link.springer.com/chapter/10.1007/978-981-19-6945-4_43>. Acesso em: 23 maio 2026.

Apêndice

Scripts de implementação, código-fonte e análise exploratória de dados disponível em: https://github.com/asagnori/Predicting_using_heterogeneous_graphs.git